Trabalho6

June 12, 2025

[1]:
```
library(pacman)
p_load(dplyr,glarma,boot)
```

[2]:
```
setwd('C:\\Users\\Marcelo\\OneDrive\\Área de Trabalho\\ts\\glarma')
getwd()
```

'C:/Users/Marcelo/OneDrive/Área de Trabalho/ts/glarma'

1 Simulação

Criando a função que simula o processo:

[8]:
```
simulate_glarma <- function(T = 100, beta = 1, theta = 0.3, x = NULL) {
  if (is.null(x)) x <- rep(1, T)

  z <- numeric(T)
  mu <- numeric(T)
  y <- numeric(T)
  e <- numeric(T)

  for (t in 1:T) {
    z_t <- 0
    if (t > 1) z_t <- + e[t - 1] * theta

    eta <- beta * x[t] + z_t
    mu[t] <- exp(eta)
    y[t] <- rpois(1, lambda = mu[t])
    e[t] <- (y[t] - mu[t]) / sqrt(mu[t])
    z[t] <- z_t
  }

  return(data.frame(time = 1:T, x = x, y = y, mu = mu, z = z,e=e))
}
```

Vou conferir se a simulação está correta:

[4]:
```
Amostra_original<-simulate_glarma(T=100,beta=1,theta=0.3,x=NULL)
```

[5]:
```
length(Amostra_original$y)
```

100

[6]:
```
summary(Amostra_original$y)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   0.00    2.00    3.00    3.37    4.25   11.00
```

[7]:
```
X <- Amostra_original$x
X <- as.matrix(X)
colnames(X) <- "Intercept"
```

[8]:
```
result=glarma(Amostra_original$y, X, phiLags = NULL ,thetaLags = c(1), type =␣
 ↪"Poi")
```

[9]:
```
Theta<-result$delta[2]
Theta
```

theta_1: 0.338920651879532

[10]:
```
Beta<-result$delta[1]
Beta
```

Intercept: 1.13435742153011

Conseguimos recuperar os parâmetros bem, está tudo certo.

2 Bootstrap paramétrico:

Antes de criar as funções para rodar o experimento Monte Carlo, vou ver se a minha ideia do bootstrap está funcionando.

[17]:
```
T=length(Amostra_original$y)
B=100
```

gerando as amostras bootstrap:

[18]:
```
mu<-Amostra_original$mu
```

[19]:
```
length(mu)
```

100

[20]:
```
Y_Bootstrap <- matrix(NA, nrow = T, ncol = B)
```

[22]:
```
for (b in 1:B){
    r = simulate_glarma(T=T,beta=1,theta=Theta,x=NULL)
    Y_Bootstrap[,b] <- r$y
    }
```

criando uma função que retorna os parâmetros estimados a partir de uma amostra:

[2]:
```
recupera_par <- function(Y_col,X) {
  fit <- tryCatch({
    glarma(Y_col, X, phiLags = NULL, thetaLags = c(1), type = "Poi")
  }, error = function(e) {
    message("GLARMA failed to converge: ", e$message)
    return(NULL)
  })

  if (!is.null(fit) && !is.null(fit$delta) && length(fit$delta) >= 2 && is.
 ↪numeric(fit$delta)) {
    return(c(beta = fit$delta[1],theta = fit$delta[2])
    )
  } else {
    return(c(beta = NA,theta = NA)
    )
  }
}
```

estimando os parâmetros para B amostras bootstrap.

[24]:
```
par_estimates <- t(apply(Y_Bootstrap, 2, function(y_col) recupera_par(y_col, X)))
```

[25]:
```
beta=par_estimates[,1]
theta=par_estimates[,2]
```

[26]:
```
par_estimates=list('beta'=beta[!is.na(beta)],'theta'=theta[!is.na(theta)])
```

A média (nas B amostras) das parâmetros está perto do valor dos parâmetros para amostar original.

[27]:
```
mean(par_estimates$beta,na.rm=TRUE)
mean(par_estimates$theta,na.rm=TRUE)
```

1.00196906653669

0.337134396509231

[28]:
```
quantile(par_estimates$theta,probs=c(0.025,0.975))
```

2.5\% 0.240781370041432 **97.5\%** 0.416456947646565

[29]:
```
hist(par_estimates$theta)
```

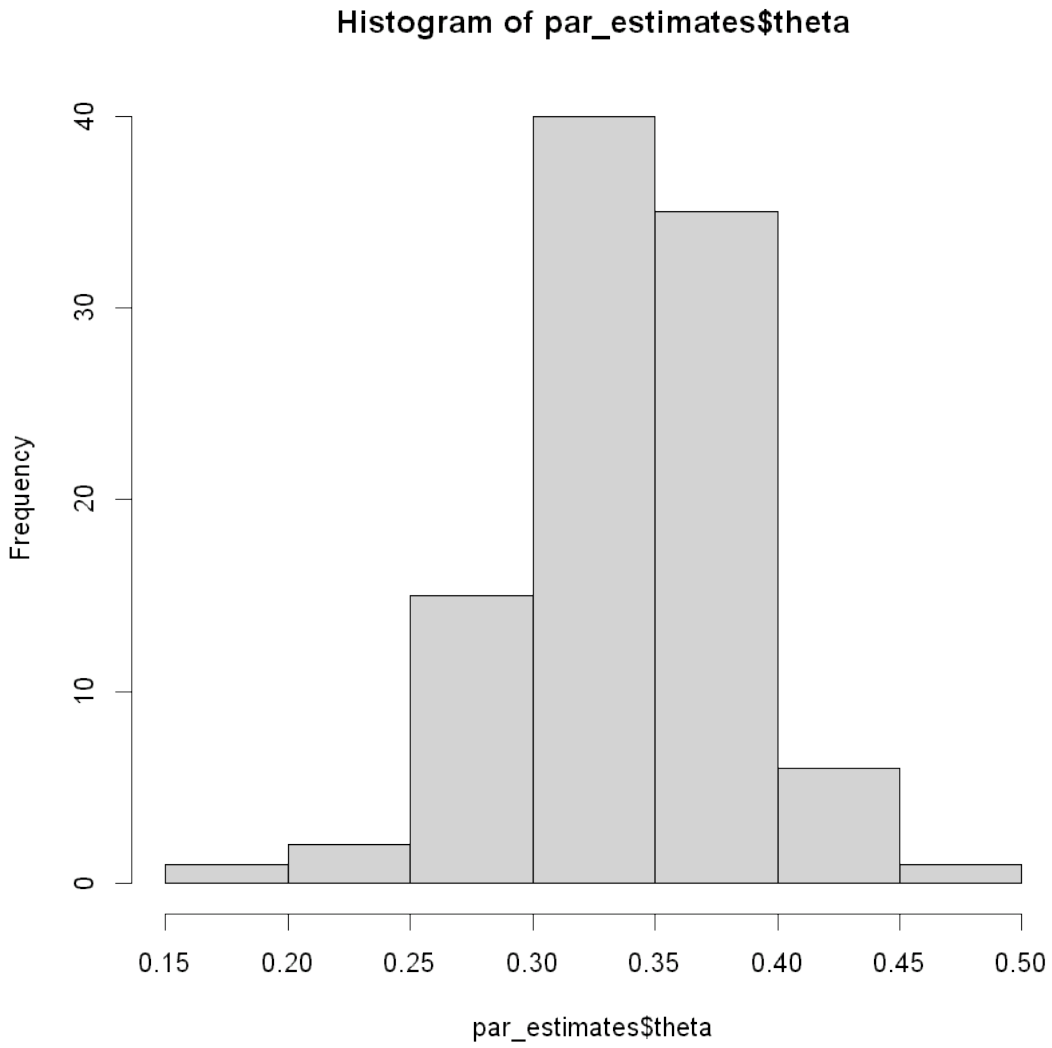

Nossa ideia para o bootstrap está funcionando, vamos fazer o experimento monte carlo:

2.0.1 Questão 1

Criando a função que faz o Bootstrap paramétrico. Ela retorna o valor dos parâmetros estimados na amostra original. Além disso, retorna os vetores Beta_boostrap e Theta_bootstrap com as estimativas para os parâmetros na amostra bootstrap. Ela também retorna a média do Beta_bootstrap e Theta_bootstrap e seus intervalos de confiança. Finalmente, ela também retorna a Amostra original.

[3]:
```
bootstrap_parametrico <- function(B=100,T=100,beta=1,theta=0.3)

    {
```

```r
  Amostra_original<-simulate_glarma(T=100,beta=1,theta=0.3,x=NULL)
  X <- Amostra_original$x
  X <- as.matrix(X)
  colnames(X) <- "Intercept"

  result=glarma(Amostra_original$y, X, phiLags = NULL ,thetaLags = c(1), type␣
↪= "Poi")
  beta_estimado<-result$delta[1]
  theta_estimado<-result$delta[2]

  T=length(Amostra_original$y)
  mu<-result$mu

  Y_Bootstrap <- matrix(NA, nrow = T, ncol = B)

  for (b in 1:B)
      {
      s = simulate_glarma(T=T,beta=beta_estimado,theta=theta_estimado,x=NULL)
      Y_Bootstrap[,b] <- s$y
      }

  par_bootstrap <- t(apply(Y_Bootstrap, 2, function(y_col) recupera_par(y_col,␣
↪X)))

  beta_bootstrap=par_bootstrap[,1]
  theta_bootstrap=par_bootstrap[,2]

  par_bootstrap=list('beta'=beta_bootstrap[!is.
↪na(beta_bootstrap)],'theta'=theta_bootstrap[!is.na(theta_bootstrap)])


  mean_beta <- mean(par_bootstrap$beta)
  mean_theta <- mean(par_bootstrap$theta)

  IC_theta<-quantile(par_bootstrap$theta, probs = c(0.025, 0.975))
  IC_beta<-quantile(par_bootstrap$beta, probs = c(0.025, 0.975))


  return(list('beta_estimado'=beta_estimado,
              'Beta_bootstrap'=par_bootstrap[1],
              'theta_estimado'=theta_estimado,
              'Theta_bootstrap'=par_bootstrap[2],
              'mean_beta'=mean_beta,
              'mean_theta'=mean_theta,
              'IC_theta'=IC_theta,
              'IC_beta'=IC_beta,
```

```
                'Amostra_original'= Amostra_original$y))
    }
```

Para ficar claro, vou rodar a função 1 vez com B=10 para ser possível ver o output:

[34]:
```
bootstrap_parametrico(B=10)
```

$beta_estimado Intercept: 0.964179131401806

$Beta_bootstrap $beta = 1. 0.945538212925242 2. 1.21973334584034 3. 1.03639181295438 4. 0.947817952520812 5. 0.995444435156517 6. 1.12120861055112 7. 0.9130322361958 8. 1.01476887581031 9. 0.976672541823167 10. 1.10089475610305

$theta_estimado theta_1: 0.339725213744957

$Theta_bootstrap $theta = 1. 0.403055697943423 2. 0.379898228610576 3. 0.330324618826487 4. 0.349029714203789 5. 0.3057417983432 6. 0.365773922398388 7. 0.385603703485939 8. 0.384991197758038 9. 0.359958406777127 10. 0.244649198880401

$mean_beta 1.02715027798807

$mean_theta 0.350902648722737

$IC_theta 2.5\% 0.258395033759531 **97.5\%** 0.399128999190489

$IC_beta 2.5\% 0.920346080959924 **97.5\%** 1.19756528040027

$Amostra_original 1. 0 2. 0 3. 1 4. 1 5. 0 6. 3 7. 3 8. 4 9. 3 10. 3 11. 5 12. 4 13. 5 14. 2 15. 0 16. 1 17. 2 18. 0 19. 0 20. 2 21. 6 22. 5 23. 3 24. 2 25. 1 26. 1 27. 5 28. 7 29. 9 30. 6 31. 1 32. 5 33. 5 34. 3 35. 1 36. 1 37. 3 38. 3 39. 2 40. 1 41. 3 42. 3 43. 1 44. 3 45. 2 46. 4 47. 5 48. 5 49. 2 50. 1 51. 2 52. 3 53. 5 54. 1 55. 2 56. 3 57. 3 58. 3 59. 3 60. 3 61. 1 62. 2 63. 2 64. 7 65. 9 66. 2 67. 1 68. 1 69. 4 70. 3 71. 2 72. 3 73. 1 74. 2 75. 4 76. 5 77. 0 78. 4 79. 7 80. 2 81. 1 82. 1 83. 0 84. 1 85. 3 86. 4 87. 4 88. 7 89. 5 90. 1 91. 3 92. 5 93. 5 94. 1 95. 1 96. 2 97. 4 98. 3 99. 0 100. 2

A função Questao1 faz o experimento Monte Carlo.Ela retorna:

um vetor de tamanho R com os parâmetros estimados da Amostra original de cada iteração (r in 1:R).

um vetor de tamanho R (r 1:R) com a média (em b 1:B) dos parâmetros bootstrap em cada iteração r.

uma lista de tamanho R com de intervalo de confiança bootstrap para cada parâmetro.

Além disso retorna quatro escalares:

mean_theta_dif_boot_est <- média (em r 1:R) de (mean_theta_bootstrap[r] - theta_estimado[r])^2 (erro quadrático médio entre o theta estimado original e a média do theta_bootstrap)

theta_dif_boot_true; média (em r 1:R) de (mean_theta_bootstrap[r] - theta)^2 (erro quadrático médio entre o theta verdadeiro e a média do theta_bootstrap)

Raciocínio análago para o beta.

[4]:
```
Questao1 <- function(B = 20, T = 100, beta = 1, theta = 0.3, R = 2) {

```

```r
theta_estimado <- numeric(R)
beta_estimado <- numeric(R)
mean_theta_bootstrap <- numeric(R)
mean_beta_bootstrap <- numeric(R)
IC_theta_bootstrap <- vector("list", R)
IC_beta_bootstrap <- vector("list", R)
theta_dif_boot_true <- numeric(R)
theta_dif_boot_est <- numeric(R)
beta_dif_boot_true <- numeric(R)
beta_dif_boot_est <- numeric(R)


for (r in 1:R) {
  result <- tryCatch({
    bootstrap_parametrico(B = B, T = T, beta = beta, theta = theta)
  }, error = function(e) {
    message(sprintf("Erro na repetição %d: %s", r, e$message))
    return(NULL)
  })

  if (!is.null(result)) {
      mean_theta_bootstrap[r] <- result$mean_theta
      mean_beta_bootstrap[r] <- result$mean_theta
      IC_theta_bootstrap[[r]] <- result$IC_theta
      IC_beta_bootstrap[[r]] <- result$IC_beta
      theta_estimado[r] <- result$theta_estimado
      beta_estimado[r] <- result$beta_estimado

      theta_dif_boot_est[r] <- (mean_theta_bootstrap[r] - theta_estimado[r])^2
      theta_dif_boot_true[r] <- (mean_theta_bootstrap[r] - theta)^2

      beta_dif_boot_est[r] <- (mean_beta_bootstrap[r] - beta_estimado[r])^2
      beta_dif_boot_true[r] <- (mean_beta_bootstrap[r] - beta)^2

  } else {
    mean_theta_bootstrap[r] <- NA
    mean_beta_bootstrap[r] <- NA

    IC_theta_bootstrap[[r]] <- c(NA, NA)
    IC_beta_bootstrap[[r]] <- c(NA, NA)
    theta_estimado[r] <- NA
    beta_estimado[r]<-NA

  theta_dif_boot_est[r] <- NA
  theta_dif_boot_true[r] <- NA

  beta_dif_boot_est[r] <- NA
```

```
    beta_dif_boot_true[r] <- NA
    }


  }

  return(list(
    'theta_estimado' = theta_estimado,
    'beta_estimado' = beta_estimado,
    'mean_theta_bootstrap' = mean_theta_bootstrap,
    'mean_beta_bootstrap' = mean_beta_bootstrap,
    'IC_theta_bootstrap' = IC_theta_bootstrap,
    'IC_beta_bootstrap' = IC_beta_bootstrap,
    'mean_theta_dif_boot_est' = mean(theta_dif_boot_est, na.rm = TRUE),
    'mean_theta_dif_boot_true' = mean(theta_dif_boot_true, na.rm = TRUE),
    'mean_beta_dif_boot_est' = mean(beta_dif_boot_est, na.rm = TRUE),
    'mean_beta_dif_boot_true' = mean(beta_dif_boot_true, na.rm = TRUE)
  ))
}
```

Para ficar mais claro, vamos rodar a função com B=20 e R=2:

[39]:
```
MM_bootstrap_parametrico<-Questao1(B=20,R=2)
```

```
GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.
```

[40]:
```
MM_bootstrap_parametrico
```

$theta_estimado 1. 0.373595101786257 2. 0.293284732046803

$beta_estimado 1. 1.01385123199714 2. 0.972661390434401

$mean_theta_bootstrap 1. 0.37490588714954 2. 0.285038538497943

$mean_beta_bootstrap 1. 0.37490588714954 2. 0.285038538497943

$IC_theta_bootstrap 1. **2.5\%** 0.339499279926336 **97.5\%** 0.410908269162711
2. **2.5\%** 0.205846749715939 **97.5\%** 0.367576003965858

$IC_beta_bootstrap 1. **2.5\%** 0.846446291604389 **97.5\%** 1.19658680583726
2. **2.5\%** 0.829021125027402 **97.5\%** 1.10518669946315

$mean_theta_dif_boot_est 3.48589331569297e-05

$mean_theta_dif_boot_true 0.00291736862996855

$mean_beta_dif_boot_est 0.440538170103822

$mean_beta_dif_boot_true 0.45095627067673

Respondendo a questão:

A função conferindo_cobertura_bootstrap responde a nossa questão 1) - ver texto abaixo do output.

[43]:
```
conferindo_cobertura_bootstrap <- function(B = 20, T = 100, beta = 1, theta = 0.
↪3, R = 100) {

 resultado <- Questao1(B = B, T = T, beta = beta, theta = theta, R = R)

 theta_estimado <- resultado$theta_estimado
 beta_estimado <- resultado$beta_estimado

 IC_theta_bootstrap <- resultado$IC_theta_bootstrap
 mean_theta_boot <- resultado$mean_theta_boot

 IC_beta_bootstrap <- resultado$IC_beta_bootstrap
 mean_beta_boot <- resultado$mean_beta_boot

 dentro_do_intervalo_theta <- logical(R)
 dentro_do_intervalo_beta <- logical(R)


for (r in 1:R) {
   intervalo_theta <- IC_theta_bootstrap[[r]]
   intervalo_beta <- IC_beta_bootstrap[[r]]

   if (any(is.na(intervalo_theta))) {
     dentro_do_intervalo_theta[r] <- NA
     dentro_do_intervalo_beta[r] <- NA
   } else {
     dentro_do_intervalo_theta[r] <- (theta >= intervalo_theta[1]) && (theta <=␣
↪intervalo_theta[2])
     dentro_do_intervalo_beta[r] <- (beta >= intervalo_beta[1]) && (beta <=␣
↪intervalo_beta[2])
   }
 }

 cobertura_percentual_theta <- mean(dentro_do_intervalo_theta, na.rm = TRUE) *␣
↪100
 cobertura_percentual_beta <- mean(dentro_do_intervalo_beta, na.rm = TRUE) * 100


 return(list(
   cobertura_percentual_theta = cobertura_percentual_theta,
   cobertura_percentual_beta = cobertura_percentual_beta,

   total_dentro_theta = sum(dentro_do_intervalo_theta,na.rm=TRUE),
```

```
    total_dentro_beta = sum(dentro_do_intervalo_beta,na.rm=TRUE),

    total_r = sum(!is.na(dentro_do_intervalo_theta)),

    mean_dif_theta_boot_true = resultado$mean_theta_dif_boot_true,
    mean_dif_theta_boot_est=resultado$mean_theta_dif_boot_est,
    mean_dif_beta_boot_true = resultado$mean_beta_dif_boot_true ,
    mean_dif_beta_boot_est=resultado$mean_beta_dif_boot_est
  ))
}
```

[44]:
```
conferindo_cobertura_bootstrap(R=100,B=100)
```

```
GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.

GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.

GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.

GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.

GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.

GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.

GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.

GLARMA failed to converge: Fisher Scoring fails to converge from the initial
estimates.
```

$cobertura_percentual_theta 92

$cobertura_percentual_beta 92

$total_dentro_theta 92

$total_dentro_beta 92

$total_r 100

$mean_dif_theta_boot_true 0.00217628359507018

$mean_dif_theta_boot_est 2.41416906439163e-05

$mean_dif_beta_boot_true 0.494160383951601

$mean_dif_beta_boot_est 0.483344169615911

O parâmetro verdadeiro está contido em 92% dos 100 intervalos de confiança. Também podemos notar que o erro quadratico médio é mais baixo quando comparamos a média do bootstrap com o parâmetro estimado do que com o parâmetro verdadeiro. Logo a distância é menor em relação ao parâmetro estimado.

3 Bootstrap Não Paramétrico

Vamos ver o que acontece no bootstrap não paramétrico:

[45]:
```
e<-Amostra_original$e
```

[46]:
```
y<-Amostra_original$y
```

[47]:
```
mu<-Amostra_original$mu
```

[48]:
```
X <- Amostra_original$x
X <- as.matrix(X)
colnames(X) <- "Intercept"
```

[49]:
```
e_boot <- replicate(B, sample(e, size = T, replace = TRUE))
```

[50]:
```
gera_y_boot <- function(e,mu)
{

    T <- length(e)
    y <- numeric(T)

    for (t in 1:T)
        {
        y[t] = mu[t] + e[t]*sqrt(mu[t])
        y[t] = round(y[t])
        }
    y[y < 1e-12] <- 0
    return(data.frame(y=y))
}
```

[51]:
```
est_bootstrap <- function(y,X)
{
  fit <- tryCatch({
    glarma(y, X, phiLags = NULL, thetaLags = c(1), type = "Poi")
  }, error = function(e) {
    message("GLARMA failed to converge: ", e$message)
    return(NULL)
  })
```

```
  if (!is.null(fit) && !is.null(fit$delta) && length(fit$delta) >= 2 && is.
 ↪numeric(fit$delta)) {
    return(c(beta = fit$delta[1],theta = fit$delta[2])
    )
  } else {
    return(c(beta = NA,theta = NA)
    )
  }
}
```

[52]:
```
gera_mu_boot <- function(e,y,x,par)
{
    z <- numeric(T)

    beta <- par[1]
    theta <- par[2]

    for (t in 1:T) {
        z_t <- 0
        if (t > 1) z_t <-  e[t - 1] * theta

        eta <- beta * x[t] + z_t
        mu[t] <- exp(eta)
        z[t] <- z_t
      }
    return(mu)
}
```

[53]:
```
bootstrap_n_parametrico <- function(e_boot, mu_init, y, X, B)
{

    T <- length(y)
    Y_Bootstrap <- matrix(NA, nrow = T, ncol = B)
    theta_boot <- numeric(B)
    beta_boot <- numeric(B)

    mu_current <- mu_init

  for (b in 1:B) {
    e <- e_boot[, b]

    y_boot <- gera_y_boot(e, mu_current)
    y_boot<-y_boot$y
    Y_Bootstrap[, b] <- y_boot

    par <- est_bootstrap(y_boot, X)
```

```
    theta_boot[b] <- par[2]
    beta_boot[b] <- par[1]

    mu_current <- gera_mu_boot(e=e, y=y_boot, x=X, par=par)
  }

  return(cbind(beta_boot,theta_boot))
}
```

[54]:
```
par_bootstrap <- bootstrap_n_parametrico(e_boot=e_boot,mu=mu,y=y,X=X,B=B)
```

[55]:
```
mean(par_bootstrap[,'theta_boot'])
```

-0.000370618399197457

[56]:
```
hist(par_bootstrap[,'theta_boot'])
```

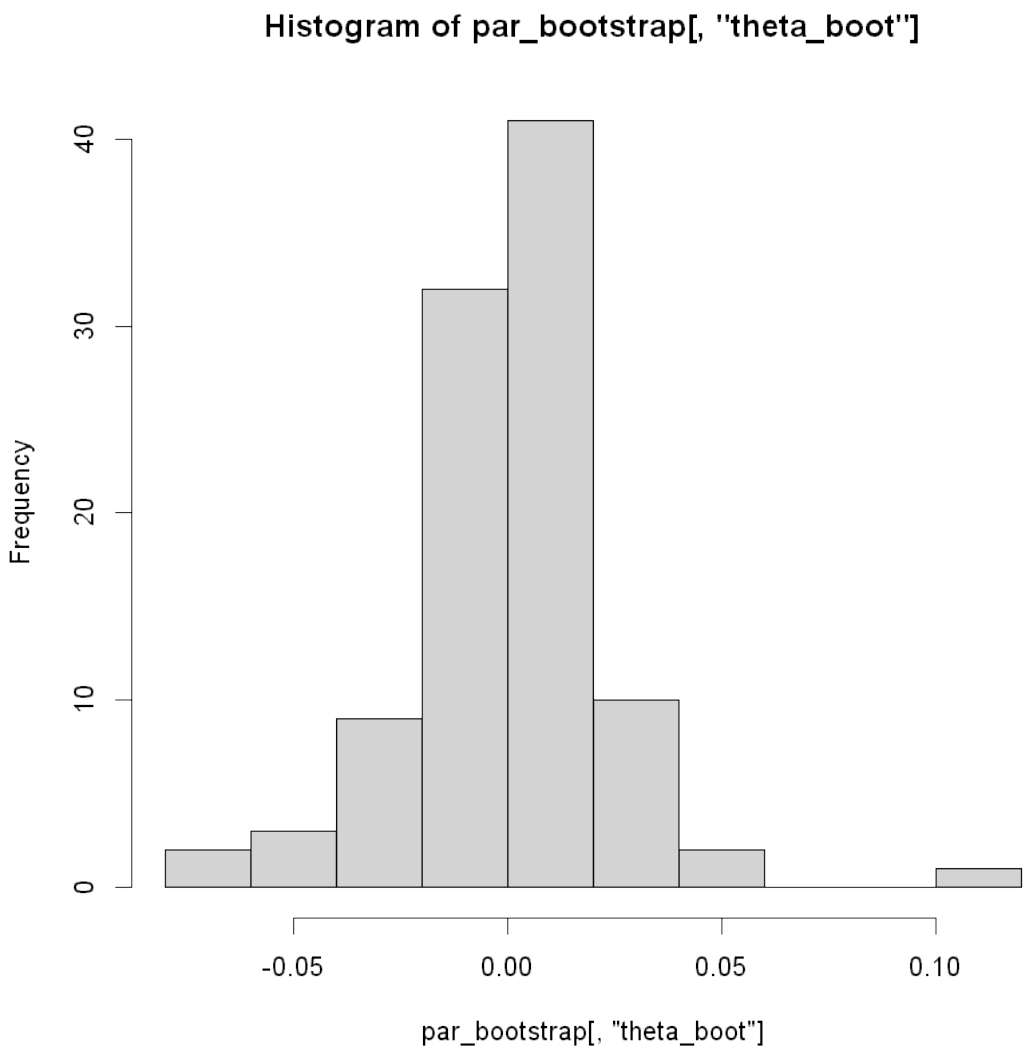

O bootstrap não paramétrico deu errado, como o esperado. Eu montei o experimento Monte Carlo para o código ficar completo:

3.0.1 Questão 2

[59]:
```
Questao2 <- function(B=20,T=100,beta=1,theta=0.3,R=2)
    {

    theta_estimado <- numeric(R)
    beta_estimado <- numeric(R)
    mean_theta_bootstrap <- numeric(R)
    mean_beta_bootstrap <- numeric(R)
    IC_theta_bootstrap <- vector("list", R)
    IC_beta_bootstrap <- vector("list", R)
    theta_dif_boot_true <- numeric(R)
    theta_dif_boot_est <- numeric(R)
    beta_dif_boot_true <- numeric(R)
    beta_dif_boot_est <- numeric(R)

    for (r in 1:R)
        {

        Amostra_original<-simulate_glarma(T=100,beta=1,theta=0.3,x=NULL)
        X <- Amostra_original$x
        X <- as.matrix(X)
        colnames(X) <- "Intercept"

        result=glarma(Amostra_original$y, X, phiLags = NULL ,thetaLags = c(1),␣
↪type = "Poi")
        beta_estimado[r]<-result$delta[1]
        theta_estimado[r]<-result$delta[2]

        e<-Amostra_original$e
        e_boot <- replicate(B, sample(e, size = T, replace = TRUE))


      ␣
↪par_bootstrap<-bootstrap_n_parametrico(e_boot=e_boot,B=20,mu_init=Amostra_original$mu,y=Amost

        Theta_bootstrap<-par_bootstrap['theta_boot']
        Beta_bootstrap<-par_bootstrap['beta_boot']


        mean_theta_bootstrap[r] <- mean(Theta_bootstrap)
        mean_beta_bootstrap[r] <- mean(Beta_bootstrap)
```

```
      IC_theta_bootstrap[[r]]<-quantile(Theta_bootstrap, probs = c(0.025, 0.
↪975))
      IC_beta_bootstrap[[r]]<-quantile(Beta_bootstrap, probs = c(0.025, 0.975))

      theta_dif_boot_est[r] <- (mean_theta_bootstrap[r] - theta_estimado[r])^2
      theta_dif_boot_true[r] <- (mean_theta_bootstrap[r] - theta)^2

      beta_dif_boot_est[r] <- (mean_beta_bootstrap[r] - beta_estimado[r])^2
      beta_dif_boot_true[r] <- (mean_beta_bootstrap[r] - beta)^2

      }
   return(list('theta_estimado'=theta_estimado,
               'beta_estimado'=beta_estimado,
               'mean_theta_bootstrap'=mean_theta_bootstrap,
               'mean_beta_bootstrap'=mean_beta_bootstrap,
               'IC_theta_bootstrap'=IC_theta_bootstrap,
              'IC_beta_bootstrap'=IC_beta_bootstrap,
               'mean_theta_dif_boot_est' = mean(theta_dif_boot_est, na.rm =␣
↪TRUE),
               'mean_theta_dif_boot_true' = mean(theta_dif_boot_true, na.rm =␣
↪TRUE),
               'mean_beta_dif_boot_est' = mean(beta_dif_boot_est, na.rm = TRUE),
               'mean_beta_dif_boot_true' = mean(beta_dif_boot_true, na.rm =␣
↪TRUE)
               ))
   }
```

Testando as funções:

[60]:
```
MM_bootstrap_n_parametrico<-Questao2(B=20,R=2)
```

[61]:
```
MM_bootstrap_n_parametrico
```

$theta_estimado 1. 0.282816431072546 2. 0.325890607844324

$beta_estimado 1. 1.04409512264816 2. 0.949878856913491

$mean_theta_bootstrap 1. -0.0133797731679488 2. -0.00509248055837412

$mean_beta_bootstrap 1. 1.18326431256418 2. 0.94886120057529

$IC_theta_bootstrap 1. **2.5\%** -0.158034161411147 **97.5\%** 0.0688101305732844
2. **2.5\%** -0.128559988372725 **97.5\%** 0.101332194159946

$IC_beta_bootstrap 1. **2.5\%** 0.944477458455162 **97.5\%** 1.46121032147708
2. **2.5\%** 0.832989816411914 **97.5\%** 1.09740571529093

$mean_theta_dif_boot_est 0.0986409981075326

$mean_theta_dif_boot_true 0.0956441519620284

$mean_beta_dif_boot_est 0.00968454952315114

$mean_beta_dif_boot_true 0.0181004925331102

[62]:
```
conferindo_cobertura_bootstrap2 <- function(B = 20, T = 100, beta = 1, theta = 0.
↪3, R = 100) {

 resultado <- Questao2(B = B, T = T, beta = beta, theta = theta, R = R)

 theta_estimado <- resultado$theta_estimado
 beta_estimado <- resultado$beta_estimado

 IC_theta_bootstrap <- resultado$IC_theta_bootstrap
 mean_theta_boot <- resultado$mean_theta_boot

 IC_beta_bootstrap <- resultado$IC_beta_bootstrap
 mean_beta_boot <- resultado$mean_beta_boot

 dentro_do_intervalo_theta <- logical(R)
 dentro_do_intervalo_beta <- logical(R)


for (r in 1:R) {
   intervalo_theta <- IC_theta_bootstrap[[r]]
   intervalo_beta <- IC_beta_bootstrap[[r]]

   if (any(is.na(intervalo_theta))) {
     dentro_do_intervalo_theta[r] <- NA
     dentro_do_intervalo_beta[r] <- NA
   } else {
     dentro_do_intervalo_theta[r] <- (theta >= intervalo_theta[1]) && (theta <=␣
↪intervalo_theta[2])
     dentro_do_intervalo_beta[r] <- (beta >= intervalo_beta[1]) && (beta <=␣
↪intervalo_beta[2])
   }
 }

 cobertura_percentual_theta <- mean(dentro_do_intervalo_theta, na.rm = TRUE) *␣
↪100
 cobertura_percentual_beta <- mean(dentro_do_intervalo_beta, na.rm = TRUE) * 100


 return(list(
   cobertura_percentual_theta = cobertura_percentual_theta,
   cobertura_percentual_beta = cobertura_percentual_beta,

   total_dentro_theta = sum(dentro_do_intervalo_theta,na.rm=TRUE),
   total_dentro_beta = sum(dentro_do_intervalo_beta,na.rm=TRUE),
```

```
    total_r = sum(!is.na(dentro_do_intervalo_theta)),

    mean_dif_theta_boot_true = resultado$mean_theta_dif_boot_true,
    mean_dif_theta_boot_est=resultado$mean_theta_dif_boot_est,
    mean_dif_beta_boot_true = resultado$mean_beta_dif_boot_true ,
    mean_dif_beta_boot_est=resultado$mean_beta_dif_boot_est
  ))
}
```

[63]:
```
conferindo_cobertura_bootstrap2(R=2)
```

$cobertura_percentual_theta 0

$cobertura_percentual_beta 0

$total_dentro_theta 0

$total_dentro_beta 0

$total_r 2

$mean_dif_theta_boot_true 0.0849217372298995

$mean_dif_theta_boot_est 0.0927827690486409

$mean_dif_beta_boot_true 0.596613767025563

$mean_dif_beta_boot_est 0.45780750192877

Já sabemos que o não paramétrico está errado, logo fiz poucas iterações.

4 Questão 3

criando a funçao que faz previsões no modelo glarma:

[5]:
```
prev_glarma <- function(y, x, beta, theta, seed = NULL) {

 futuro_x <- rep(mean(x[, 1], na.rm = TRUE), 1)

  if (!is.null(seed)) set.seed(seed)

  T <- length(y)
  mu <- numeric(T)
  e <- numeric(T)
  z <- numeric(T)

  #passo 1, recontruir z,e,mu

  for (t in 1:T) {

    z_t <- if (t > 1) e[t - 1] * theta else 0
```

```
    eta <- beta * x[t] + z_t
    mu[t] <- exp(eta)
    e[t] <- (y[t] - mu[t]) / sqrt(mu[t])
    z[t] <- z_t
  }

    e_t <- e[T]

    z_t <- e_t * theta

    eta <- beta * futuro_x + z_t

    y_pred <-  exp(eta)



  return(list('y_pred'= y_pred))
}
```

criando uma função que faz o Intervalo preditivo bootstrap utilizando o bootstrap paramétrico já apresentado.

[42]:
```
intervalo_preditivo_bootstrap <- function(T=100,B=100, beta = 1, theta = 0.
↪3,R=2){

    mean_Y_pred <- numeric(R)
    IC_pred <- vector("list", R)
    Y_teste <- numeric(R)

    x_train <- rep(1,(T-1))
    x_train <- as.matrix(x_train)
    colnames(x_train) <- "Intercept"

    for (r in 1:R)
    {

    Y_pred<-numeric(B)
    beta_boot<-numeric(B)
    theta_boot<-numeric(B)

    boot <- bootstrap_parametrico(T=T,B=B, beta = 1, theta = 0.3)

    Y <- boot$Amostra_original
    Y_train = Y[1:(T-1)]
    Y_test = Y[T]

    theta_boot<-boot$Theta_bootstrap$theta
```

```
    beta_boot<-boot$Beta_bootstrap$beta

    for (b in 1:B)
        {
       ␣
↪prev<-prev_glarma(y=Y_train,x=x_train,beta=beta_boot[b],theta=theta_boot[b])
        Y_pred[b]<-prev$y_pred
        }

    mean_Y_pred[r]=mean(Y_pred,na.rm=TRUE)
    IC_pred[[r]]<-quantile(Y_pred,probs = c(0.025, 0.975),na.rm=TRUE)
    IC_pred[[r]] <- c(floor(IC_pred[[r]][1]), ceiling(IC_pred[[r]][2]))

    Y_teste[r]<-Y_test
    }

        return(list('Y_test'=Y_teste,'IC_pred'=IC_pred))
}
```

Eu arredondei os limites dos intervalos para o inteiro mais próximo, pois o Y_test é inteiro.

conferindo_IP verifica o percentual de intervalos que contém o Y_teste:

[38]:
```
conferindo_IP <- function(B = 100, T = 100, beta = 1, theta = 0.3, R=2) {

  dentro_do_intervalo <- logical(R)

    resultado <- intervalo_preditivo_bootstrap(T=T,B=B, beta = beta, theta =␣
↪theta,R=R)

    Y_test <- resultado$Y_test
    IC_pred <- resultado$IC_pred

  for (r in 1:R) {

    intervalo <- IC_pred[[r]]

    if (any(is.na(intervalo))) {
      dentro_do_intervalo[r] <- NA
    } else {
    dentro_do_intervalo[r] <- (Y_test[r] >= intervalo[1]) && (Y_test[r] <=␣
↪intervalo[2])
    }
  }

  cobertura_percentual <- mean(dentro_do_intervalo,na.rm = TRUE) * 100

  return(list(
```

```
    total_dentro = sum(dentro_do_intervalo,na.rm = TRUE),
    cobertura_percentual = cobertura_percentual,
    total_R = sum(!is.na(dentro_do_intervalo))
  ))

}
```

[39]:
```
conferindo_IP(R=10,B=50)
```

$total_dentro 8

$cobertura_percentual 80

$total_R 10

Nos 10 experimentos feitos, o Y_teste está no intervalo 8 vezes.